

Instituto Nacional de Astrofísica, Óptica y Electrónica

Coordinación de Ciencias Computacionales

Laboratorio de Visión por Computadora

Reporte de Estancia de Investigación

Proyecto:

Normalización y alineación automática de la forma de la región pulmonar integrada con selección de características discriminantes para detección automática de neumonía y COVID-19

Estudiante: Rafael Alejandro Cruz Ovando

Director: Dr. Leopoldo Altamirano Robles

Institución de origen: Benemérita Universidad Autónoma de Puebla

Período: 9 de octubre – 9 de noviembre de 2025

Enero 2026

1. Resumen Ejecutivo

Se desarrolló un sistema completo para la detección automática de puntos de referencia pulmonares y normalización geométrica de radiografías de tórax para clasificación de COVID-19. El sistema combina un ensemble de modelos ResNet-18 con Coordinate Attention, funciones de pérdida geométricas especializadas, y un proceso de warping afín por partes basado en triangulación de Delaunay.

Métrica	Valor Obtenido
Error de puntos de referencia (ensemble + TTA)	3.61 px
Error de puntos de referencia (mejor individual)	4.04 px
Accuracy clasificación (validación cruzada 5-fold)	98.60 %
F1-macro validación cruzada	98.00 % $\pm$ 0.36 %

Cuadro 1: Métricas principales del sistema desarrollado.

Contribuciones principales: (1) Sistema de detección de puntos de referencia mediante ensemble de 4 modelos con Test-Time Augmentation; (2) Normalización geométrica que reduce variabilidad anatómica inter-paciente; (3) Funciones de pérdida geométricas (Wing Loss con restricciones de simetría y alineación central); (4) Infraestructura reproducible basada en configuraciones JSON y documentación exhaustiva.

2. Introducción

2.1 Contexto y Objetivos

La pandemia de COVID-19 resaltó la necesidad de herramientas de diagnóstico rápido y automatizado. Las radiografías de tórax ofrecen una alternativa accesible a las pruebas PCR, pero su interpretación requiere experiencia especializada. Este proyecto aborda dos desafíos fundamentales: (1) la detección automática de 15 puntos de referencia que definen el contorno pulmonar bilateral, y (2) la normalización geométrica mediante transformación de imágenes a una forma estándar que elimina variabilidad anatómica. La detección precisa de puntos de referencia permite normalizar variaciones debidas a diferencias individuales, posicionamiento durante adquisición, y rotaciones/escalas variables, mejorando la robustez de sistemas de clasificación downstream.

2.2 Estructura de Puntos de Referencia

El sistema utiliza 15 puntos de referencia que definen el contorno pulmonar bilateral. A diferencia de landmarks anatómicos tradicionales (como clavículas o costillas), estos puntos capturan la forma completa del campo pulmonar, permitiendo normalización geométrica posterior:

- **Eje central vertical:** L1 (ápex) $\rightarrow$ L9 $\rightarrow$ L10 $\rightarrow$ L11 $\rightarrow$ L2 (base) en posiciones verticales $t = [0, 0.25, 0.50, 0.75, 1.0]$
- **Contorno izquierdo:** L12, L3, L5, L7, L14 (distribuidos en ápex, lateral superior, lateral medio, lateral inferior, base)

- **Contorno derecho:** L13, L4, L6, L8, L15 (distribución simétrica al contorno izquierdo)
- **Pares simétricos:** (L3,L4), (L5,L6), (L7,L8), (L12,L13), (L14,L15) — explotados por Soft Symmetry Loss

Esta estructura balanceada permite capturar asimetrías patológicas reales mientras penaliza variabilidad no anatómica.

3. Metodología Implementada

3.1 Datos y Preprocesamiento

Se utilizó el *COVID-19 Radiography Dataset* con 15,153 imágenes anotadas (3 clases: COVID, Normal, Viral_Pneumonia), divididas en 75 % entrenamiento, 15 % validación, y 10 % prueba. El preprocesamiento para detección de puntos de referencia aplica CLAHE (Contrast Limited Adaptive Histogram Equalization) con `clip_limit=2.0` y `tile_size=4` para mejorar contraste local y resaltar bordes del contorno pulmonar, seguido de redimensionamiento a 224×224 píxeles y normalización con estadísticas de ImageNet. Durante entrenamiento se aplican aumentaciones: rotación ($\pm 10^\circ$), traslación ($\pm 5\%$), escalado (0.95–1.05), y flip horizontal con corrección de pares simétricos.

3.2 Arquitectura del Modelo

Componente	Especificación
Backbone	ResNet-18 (pretrained ImageNet)
Coordinate Attention	Sí (después de layer4)
Cabeza de regresión	Deep Head (768 dim, 2 capas ocultas)
Dropout	0.3
Salida	30 valores (15 puntos $\times$ 2 coordenadas)

Cuadro 2: Especificaciones de la arquitectura del modelo.

Se utiliza ResNet-18 pre-entrenado como extractor de características. El mecanismo de *Coordinate Attention* codifica información posicional en los canales y captura relaciones horizontales y verticales independientemente, mejorando la localización precisa de puntos de referencia. La cabeza de regresión profunda procesa las características del backbone a través de dos capas ocultas con ReLU y Dropout antes de predecir las 30 coordenadas normalizadas.

Implementación: `src_v2/models/resnet_landmark.py`

3.3 Funciones de Pérdida

Se implementó un sistema de pérdidas combinadas que incorpora restricciones geométricas:

Wing Loss (pérdida principal): Función robusta para regresión de puntos de referencia que da mayor peso a errores pequeños:

$$L(x) = \begin{cases} \omega \cdot \ln(1 + |x|/\epsilon) & \text{si } |x| < \omega \\ |x| - C & \text{si } |x| \geq \omega \end{cases} \quad (1)$$

donde $C = \omega - \omega \cdot \ln(1 + \omega/\epsilon)$, $\omega = 10$, $\epsilon = 2$.

Central Alignment Loss: Penaliza desviaciones de puntos de referencia centrales (L9, L10, L11) respecto al eje vertical mediante MSE entre sus coordenadas x y el valor objetivo 0.5 (centro normalizado).

Soft Symmetry Loss: Penaliza asimetrías excesivas (superiores a 6 píxeles) entre pares de puntos de referencia simétricos, permitiendo asimetría natural en anatomía real. Solo se activa la penalización cuando la diferencia de distancias al eje central excede el margen.

Combined Loss: Combinación ponderada con pesos: `wing_weight=1.0`, `symmetry_weight=0.1`, `alignment_weight=0.05`.

Implementación: `src_v2/models/losses.py`

3.4 Estrategia de Entrenamiento

Se implementó un esquema de entrenamiento en dos fases con tasas de aprendizaje diferenciadas:

Fase	Fase 1	Fase 2
Épocas	15	100 (early stopping)
Learning rate	1×10^{-3}	Backbone: 2×10^{-5} Cabeza: 2×10^{-4}
Backbone	Congelado	Descongelado
Scheduler	–	ReduceLROnPlateau
Objetivo	Estabilizar regresión	Fine-tuning completo

Cuadro 3: Parámetros de las dos fases de entrenamiento.

La Fase 1 entrena solo la cabeza de regresión con el backbone congelado para estabilizar la predicción inicial. La Fase 2 descongela el backbone y aplica fine-tuning con tasas de aprendizaje diferenciadas, usando un scheduler que reduce LR en plateaus y early stopping con paciencia de 20 épocas.

Implementación: `src_v2/training/trainer.py`

3.5 Ensemble y Test-Time Augmentation

El sistema final combina 4 modelos entrenados con diferentes semillas (123, 321, 111, 666):

Modelo	Semilla	Error Individual
1	seed123	4.15 px
2	seed321	4.08 px
3	seed111	4.12 px
4	seed666	4.10 px
Ensemble + TTA	–	3.61 px

Cuadro 4: Modelos del ensemble y sus errores individuales.

Durante inferencia se aplica *Test-Time Augmentation* (TTA) procesando cada imagen normal y con flip horizontal. Para la versión con flip se corrigen las coordenadas x ($x' = 1,0 - x$) y se intercambian pares simétricos (L3↔L4, L5↔L6, L7↔L8, L12↔L13, L14↔L15), promediando ambas predicciones.

3.6 Normalización Geométrica

Una vez detectados los puntos de referencia, se normaliza la geometría mediante tres pasos:

(1) Generalized Procrustes Analysis (GPA): Se calcula la forma canónica a partir de las anotaciones de entrenamiento mediante alineación iterativa. El algoritmo alinea todas las formas a una media actual usando transformaciones de similitud (traslación, rotación, escala), recalcula la nueva media, y repite hasta convergencia ($< 10^{-6}$).

(2) Triangulación de Delaunay: Se genera una malla de triángulos sobre los 15 puntos de referencia más las 4 esquinas de la imagen, obteniendo una partición de la región de interés en triángulos no superpuestos.

(3) Warping afín por partes: Cada triángulo se transforma independientemente calculando una transformación afín desde los vértices origen (landmarks detectados) a los vértices destino (forma canónica). Se aplica `cv2.warpAffine` por triángulo, creando máscaras y combinando regiones transformadas.

Para clasificación, las imágenes warped se procesan con SAHS (Statistical Asymmetrical Histogram Stretching) que normaliza el histograma global solo en la región pulmonar (píxeles > 10) usando límites asimétricos ($\pm 2,5\sigma$ superior, $\pm 2,0\sigma$ inferior), preservando patrones patológicos.

Implementación: `src_v2/processing/gpa.py`, `src_v2/processing/warp.py`

4. Resultados y Análisis

4.1 Detección de Puntos de Referencia

Configuración	Error Medio	Std	Mediana
Mejor modelo individual (seed456)	4.04 px	–	–
Ensemble 4 modelos	3.71 px	2.42 px	3.17 px
Ensemble + TTA (mejor)	3.61 px	2.48 px	3.07 px

Cuadro 5: Comparación de configuraciones de detección de puntos de referencia.

Categoría	Error (px)
Normal	3.22
COVID	3.93
Viral_Pneumonia	4.11

Cuadro 6: Error de puntos de referencia por categoría diagnóstica.

Punto	Error (px)	Ubicación	Punto	Error (px)
L1	3.22	Ápex central	L9	2.76
L2	3.96	Base central	L10	2.44
L3	3.18	Lateral izq.	L11	2.94
L4	3.65	Lateral der.	L12	5.43
L5	2.88	Lateral izq.	L13	5.35
L6	2.94	Lateral der.	L14	4.39
L7	3.29	Lateral izq.	L15	4.29
L8	3.50	Lateral der.		

Cuadro 7: Error de detección por punto de referencia individual (ensemble + TTA).

Los puntos centrales (L9, L10, L11) tienen menor error debido a menor variabilidad anatómica. Los puntos en ápices (L12, L13) presentan mayor error por la dificultad de definir límites precisos en zonas donde la transición pulmón-aire es gradual.

4.2 Clasificación

Métrica	Valor	Std
Accuracy	98.60 %	± 0.26 %
F1-macro	98.00 %	± 0.36 %
F1-weighted	98.60 %	± 0.25 %

Cuadro 8: Resultados de validación cruzada 5-fold (ResNet-18 en dataset warped_lung_best).

4.3 Impacto de la Normalización Geométrica

El proceso de warping demostró dos beneficios principales: (1) **Reducción de variabilidad**: la normalización a forma canónica elimina diferencias de posicionamiento y anatomía individual, permitiendo que el clasificador se enfoque en patrones patológicos; (2) **Información preservada**: el warping afín por partes (no lineal globalmente) mantiene características locales relevantes como consolidaciones y opacidades.

5. Entregables

Se produjo un sistema completo con la siguiente estructura:

5.1 Código Fuente

Implementación completa en `src_v2/` organizada en módulos:

- **Modelos:** `resnet_landmark.py` (arquitectura ResNet-18 con Coordinate Attention), `losses.py` (Wing Loss, Symmetry, Alignment), `classifier.py` (clasificador COVID-19)
- **Entrenamiento:** `trainer.py` (esquema dos fases), `callbacks.py` (early stopping, checkpointing)
- **Datos:** `dataset.py` (LandmarkDataset), `transforms.py` (CLAHE, TTA, aumento)
- **Procesamiento:** `gpa.py` (Generalized Procrustes Analysis), `warp.py` (warping afín por partes)
- **Evaluación:** `metrics.py` (error de puntos de referencia), `ensemble.py` (predicción ensemble)
- **CLI:** `cli.py` (interfaz de línea de comandos para todos los comandos)

6. Cronograma

Semana	Plan Original	Actividades Ejecutadas
1 (9-15 Oct)	Revisión estado del arte, análisis dataset	Análisis de 15,153 imágenes, definición de 15 puntos de referencia, configuración entorno
2 (16-22 Oct)	Arquitectura base, Fase 1	Implementación ResNet-18 + CoordAttention, entrenamiento Fase 1
3 (23-29 Oct)	Fine-tuning, Fases 2-3	Fine-tuning diferenciado, pérdidas geométricas, sweep semillas
4 (30 Oct-9 Nov)	Experimentos finales, documentación	Ensemble 4 modelos, TTA, clasificación, documentación

Cuadro 9: Comparación entre cronograma planificado y ejecutado.