

Enfoque de expansión estadística de histograma asimétrico para mejorar el contraste en imágenes de radiografías de tórax para la detección de neumonía

Statistical asymmetrical histogram stretching approach for contrast enhancement in chest X-ray images for pneumonia detection

Rafael Alejandro Cruz Ovando¹, Salvador E. Ayala Raggi¹, Ángel E. Picazo Castillo²,
Aldrin Barreto Flores¹, José Francisco Portillo Robledo¹,

¹Benemérita Universidad Autónoma de Puebla, Av. San Claudio s/n, Cd Universitaria, C.P. 72592, Puebla, Puebla, México.

²Instituto Nacional de Astrofísica, Óptica y Electrónica, Luis Enrique Erro #1, C.P. 72840. Sta. María Tonantzintla, Puebla, México.

co223470443@alm.buap.mx, salvador.raggi@correo.buap.mx, angel.picazo@inaoep.mx, aldrin.barreto@correo.buap.mx, francisco.portillo@correo.buap.mx.

Abstract

This paper presents a novel approach to enhance contrast in chest X-ray images which improves pneumonia detection when using several convolutional neural networks (CNNs). We introduce a Statistical Asymmetrical Histogram Stretching (SAHS) technique, which addresses the inherent asymmetry in chest X-ray image histograms. Our approach is compared with conventional techniques, like HE and CLAHE, across various CNN architectures including AlexNet, Compact, Enhanced, ResNet-18, MobileNetV2, and ResNet-50. The SAHS method, combined with a Lung Finder Algorithm (LFA), significantly improved classification accuracy across all tested CNN models. SAHS consistently outperformed CLAHE, demonstrating its effectiveness in preserving critical information like bright regions which usually indicate pneumonia. Our results show that SAHS is a valuable preprocessing technique for pneumonia recognition in chest X-ray imagery.

Resumen

Este artículo presenta un enfoque novedoso para mejorar el contraste en las imágenes de radiografías de tórax, lo que mejora la detección de neumonía cuando se utilizan varias redes neuronales convolucionales (CNN). Presentamos una técnica de estiramiento estadístico de histograma asimétrico (SAHS), que aborda la asimetría inherente en los histogramas de imágenes de rayos X de tórax. Nuestro enfoque se compara con técnicas convencionales, como HE y CLAHE, en varias arquitecturas CNN, incluidas AlexNet, Compact, Enhanced, ResNet-18, MobileNetV2 y

Fecha de recepción: 5 de agosto, 2024 / Fecha de aceptación: 7 de octubre, 2024

ResNet-50. El método SAHS, combinado con un algoritmo Lung Finder (LFA), mejoró significativamente la precisión de la clasificación en todos los modelos CNN probados. SAHS superó consistentemente a CLAHE, lo que demuestra su eficacia a la hora de preservar información crítica, como regiones brillantes que normalmente indican neumonía. Nuestros resultados demuestran que SAHS es una técnica de preprocesamiento valiosa para el reconocimiento de neumonía en imágenes de radiografía de tórax.

Keywords and phrases: Pneumonia Detection, Medical Image Normalization, CNNs, Contrast Enhancement in Medical Images, Histogram Stretching.

2020 Mathematics Subject Classification: 68N01

1 Introducción

La neumonía es una enfermedad respiratoria grave que puede ser causada por diversos agentes patógenos, incluyendo virus, bacterias y hongos. Su diagnóstico preciso a partir de imágenes radiográficas de tórax es crucial en el campo de la medicina, especialmente en situaciones de alta demanda como pandemias [1]. Sin embargo, la variabilidad en el contraste de estas imágenes puede afectar significativamente la precisión de la detección, llevando potencialmente a clasificaciones erróneas, como se ha observado en estudios previos [2,3]. La detección de neumonía en radiografías de tórax depende en gran medida de la identificación de zonas nubosas características, conocidas como opacidades o infiltrados [4]. No obstante, la calidad y el contraste de estas imágenes pueden variar considerablemente, lo que plantea un desafío significativo para los métodos de procesamiento de imágenes existentes [5,6]. Esta variabilidad se ve intensificada en los bancos de imágenes disponibles, donde la falta de uniformidad en la alineación y el brillo de la región de interés (los pulmones) es evidente [2]. La mejora del contraste en imágenes médicas ha sido un área de investigación activa durante décadas, con una evolución constante de técnicas y métodos. La Ecualización del Histograma (HE) ha sido una técnica fundamental en este campo, sirviendo como base para muchos desarrollos posteriores [5]. S. Patel et al. [7] realizaron un estudio comparativo de varias técnicas de ecualización de histograma, revelando que mientras la HE mejora el contraste general, puede llevar a una coloración falsa y pérdida de información. N. Salem et al. [8] ampliaron este estudio, evaluando técnicas más avanzadas como la Ecualización del Histograma Adaptativa con Contraste Limitado (CLAHE) y la Ecualización Dinámica del Histograma por Cuadrantes (QDHE). Sin embargo, estos métodos presentan limitaciones cuando se aplican a imágenes radiográficas de tórax [9]. CLAHE, por ejemplo, al ser una ecualización local, tiende a homogeneizar y realzar el contraste en zonas donde no debería, potencialmente destruyendo información crucial relacionada con la suavidad de las zonas nubosas indicativas de neumonía [9,10]. Además, puede introducir ruido en las zonas de fondo de la imagen, complicando aún más el proceso de diagnóstico [9]. Otro aspecto importante de considerar es la naturaleza asimétrica de los histogramas en las imágenes radiográficas de tórax [11]. Esta característica sugiere que los métodos basados en la desviación estándar simétrica podrían no ser óptimos para este tipo de imágenes, como se ha demostrado en estudios [12,13]. En este contexto, proponemos un nuevo método para mejorar el contraste en

imágenes radiográficas de tórax, diseñado específicamente para abordar los desafíos mencionados. Nuestro enfoque se basa en una expansión asimétrica del histograma, utilizando diferentes desviaciones estándar para los valores de gris mayores y menores que la media. Este método busca mejorar el contraste de manera más efectiva que las técnicas existentes, preservando al mismo tiempo la información importante para el diagnóstico de neumonía. Para evaluar la efectividad de nuestro método de mejora de contraste, empleamos una variedad de arquitecturas de redes neuronales convolucionales (CNN) para la clasificación de imágenes radiográficas. Entre las arquitecturas utilizadas se encuentran MobileNetV2, ResNet-50, ResNet-18, Compact, Enhanced y AlexNet, todas disponibles en la plataforma MVTEC Deep Learning Tool [14]. El propósito principal es evaluar cómo las diferentes técnicas de mejora de contraste afectan la precisión de la clasificación de radiografías de tórax utilizando estos diversos modelos de CNN. Este enfoque nos permite no solo comparar la eficacia de las técnicas de preprocesamiento, sino también analizar cómo interactúan con las distintas arquitecturas de redes neuronales. Este trabajo se organiza en cuatro secciones principales. En la Sección 2, se realiza un análisis detallado de los histogramas asimétricos característicos de las imágenes radiográficas de tórax y se explica nuestro método propuesto para la mejora de contraste de histogramas asimétricos y la normalización de la región pulmonar. A continuación, en la Sección 3, se describen los experimentos realizados para evaluar la eficacia del método, comparando el rendimiento de nuestro enfoque con técnicas convencionales de ajuste de contraste. Finalmente, la Sección 4 realiza las conclusiones del trabajo.

2. Metodología

Esta sección analiza los histogramas asimétricos característicos de las radiográficas de tórax, y propone una técnica de mejora de contraste basada en dicha asimetría.

2.1 Preprocesamiento en Detección de Neumonía

La Tabla 1 proporciona una visión general de los enfoques más recientes en la clasificación de radiografías de tórax, destacando la variedad de técnicas de preprocesamiento y arquitecturas de CNN utilizadas. Esta comparación muestra el beneficio de usar técnicas de preprocesamiento tales como la mejora del contraste que aumentan la precisión en la detección de neumonía.

Tabla 1. Artículos que realizan la detección de neumonía en radiografías de tórax utilizando CNN.

Autor	Preprocesamiento	Clasificador	Exactitud
Kundur et al. [15]	Sin usar	VGG16, ResNet, Custom CNN	87.5%
Kavitha et al. [16]	Sin usar	Custom CNN	89%
Ramli et al. [17]	DWT, Filtro bilateral	Custom CNN	96%
Kanjanasurat et al. [18]	Normalización, corrección gamma, CLAHE	ResNet152V2	94.14%

2.2 Características de los histogramas en imágenes radiográficas de tórax

Las imágenes radiográficas de tórax típicamente muestran una distribución de intensidades no uniforme, con una tendencia hacia los tonos más oscuros debido a las áreas oscuras de aire en los

pulmones [6]. Esta característica resulta en histogramas que son notablemente asimétricos, con una forma característica [9] como se muestra en la Figura 1, donde aparece un pico angosto a extrema la izquierda, siguiendo una zona larga y de poca amplitud que crece hasta un máximo prominente a la derecha.




Figura 1. Visualización en diferentes imágenes de la forma característica de los histogramas en radiografías de tórax.

2.3 Efectos de diferentes tipos de ajuste de contraste en la clasificación

Ecualización del histograma (HE). Aunque es una técnica eficaz para normalizar u homogeneizar un banco de imágenes, se basa en equilibrar u homogeneizar las cantidades de píxeles para todos los niveles de gris de la imagen. En el caso específico de las imágenes pulmonares esto puede comprometer el proceso de clasificación teniendo en cuenta que las imágenes con neumonía presentan una mayor cantidad de zonas claras o blancas dentro de los pulmones que las imágenes sin neumonía.

Ecualización local del histograma (CLAHE: “Ecualización de Histograma Adaptativa Limitada al Contraste”). Aunque esta técnica resulta de mucha ayuda en imágenes que presentan el defecto de tener diferentes contrastes en diferentes lugares de la imagen, para el caso de la clasificación volveríamos a observar el mismo problema que con la técnica HE. Adicionalmente, CLAHE tiene el problema de enfatizar el ruido en zonas suaves de la imagen, lo que podría ocasionar que algunas regiones originalmente suaves y limpias se confundan con “zonas de infección” falsas comprometiendo también la clasificación correcta. En general, cuando se aplica CLAHE a imágenes destinadas a la clasificación, surgen limitaciones significativas [9]. Estas incluyen la posible destrucción de información sutil relevante para la clasificación y la introducción de imperfecciones que no están relacionados con las características distintivas entre las clases a considerar: neumonía y normal en nuestro caso.

Expansión del histograma (HS). La expansión del histograma tendría la ventaja de no cambiar las proporciones de zonas blancas y oscuras en la imagen. Sin embargo, la utilización de un mínimo global y de un máximo global puede hacer que el ajuste falle cuando hay presencia de algunos píxeles espurios contaminando la imagen. Por esta última razón, sería más razonable calcular un mínimo promedio y un máximo promedio de los niveles de gris de la imagen. La desviación estándar puede ser útil para esto. No obstante, y dado que los histogramas de este tipo de imágenes son asimétricos como lo muestra la Figura 1, utilizar alguna proporción de la desviación estándar tanto hacia arriba de la media como hacia debajo de la media para obtener el máximo y el mínimo tampoco resultaría adecuado, pues en muchas imágenes el mínimo calculado de esta forma estaría cercano al mínimo absoluto pero el máximo podría quedar muy por arriba del máximo absoluto, o bien al revés (Figura 2).




Figura 2. Ilustración en diferentes imágenes del máximo y mínimo estadístico, se puede observar que, al usar estos límites basados en 1.5 veces la desviación estándar, se mejora la representación del rango de intensidades, esto demuestra que si usamos la desviación común puede ser que quede bien hacia arriba de la desviación estándar, pero se encuentren conflictos hacia debajo de la desviación estándar, por ello se debe usar una desviación asimétrica y poder obtener así los máximos y mínimos estadísticos que se adapten mejor a lo necesitado.

2.3 Ajuste de contraste por expansión del histograma basado en la asimetría (SAHS)

En este artículo se propone un método de mejora de contraste que se basa en el cálculo de dos desviaciones promedio para los valores de gris por encima y por debajo de la media del histograma.

Si consideramos a $I(x,y)$ como la imagen de entrada de tamaño $n \times m$, y que está en escala de grises, donde $I(x,y)$ representa la intensidad del píxel (x,y) , y en donde tanto x como y son números naturales que van de 1 a n y de 1 a m respectivamente. La media de intensidad μ es:

$$\mu = \frac{1}{N} \sum_{x,y} I(x,y) \quad (1)$$

donde N es el número total de píxeles en la imagen.

Separación de niveles de gris:

$A = \{\text{valores de } I(x,y) \mid I(x,y) > \mu\}$ (valores por encima de la media)

$B = \{\text{valores de } I(x,y) \mid I(x,y) \leq \mu\}$ (valores por debajo o iguales de la media)

Cálculo de los límites de expansión:

Límite superior: $u = \mu + 2.5 \partial_+$

Límite inferior: $l = \mu - 2 \partial_-$

Donde ∂_+ y ∂_- son las desviaciones promedio de A y B con respecto a la media general μ :

$$\sigma_+ = \sqrt{\frac{1}{\#A} \sum_{\forall a \in A} (I(x, y) - \mu)^2} \quad (2)$$

$$\sigma_- = \sqrt{\frac{1}{\#B} \sum_{\forall b \in B} (I(x, y) - \mu)^2} \quad (3)$$

Utilizando u y l como máximo y mínimo niveles de gris encontrados en la imagen $I(x, y)$, podemos establecer una función de mapeo:

$$I'(x, y) = 255 \cdot \frac{I(x, y) - l}{u - l} \quad (4)$$

Donde $I'(x, y)$ sería la imagen corregida en contraste. Por otro lado, en la práctica se forzaría mediante una función de recorte a que los valores de $I'(x, y)$ fueran enteros sin signo de 8 bits (0 – 255), y aquellos que resultasen mayores a 255 serían igualados a 255, mientras que los valores negativos serían igualados a 0.

Este método además de ser computacionalmente más ligero que CLAHE, ofrece ventajas para el caso específico del tipo de histograma asimétrico típico en esta clase de imágenes radiográficas de tórax. En la Figura 3 se muestra que CLAHE enfatiza el ruido en una radiografía sin neumonía, haciendo parecer que pudiera haber lesiones (segundo trío imágenes). En el tercer trío de la misma Figura 3 se ilustra que las regiones claras de una imagen con neumonía podrían ser oscurecidas por CLAHE, no siendo así cuando se usa SAHS. Finalmente, la Figura 4 se el ajuste de contraste SAHS para 3 imágenes diferentes.



Figura 3. Comparación original, CLAHE y SAHS en una radiografía, mostrando así que CLAHE agrega imperfecciones.




Figura 4. Comparación de imágenes radiográficas de tórax con neumonía antes y después de aplicar SAHS.

2.4 Algoritmo Localizador de Pulmones (ALP)

Para mejorar la precisión de la clasificación hemos usado el Algoritmo Localizador de Pulmones (ALP) propuesto en [19, 20], que permite extraer o segmentar la región de interés (ROI) pulmonar en las radiografías. El ALP utiliza regresión K-NN para estimar las coordenadas de la ROI en una nueva imagen radiografía de prueba.

El proceso del ALP se resume en los siguientes pasos:

1. Identificación de landmarks: Se definen cuatro puntos clave (Q1, Q2, Q3, Q4) que delimitan la región pulmonar.
2. Regresión K-NN: Se predicen las coordenadas de estos puntos en la imagen de prueba.
3. Warping: Se aplica una transformación geométrica para extraer la ROI y normalizarla a una imagen de 256x256 píxeles.




Figura 5. Proceso ALP, imágenes de ejemplo con sus regiones de interés ya extraídas en imágenes procesadas con SAHS. Las coordenadas rojas son obtenidas por regresión y las azules se usan en la extracción de la ROI.

Este enfoque asegura que todas las imágenes procesadas tengan la misma alineación, lo cual mejora la clasificación [19,20].

2.5 Integración de métodos SAHS y ALP

La combinación de SAHS con ALP proporciona un preprocesamiento robusto para las imágenes radiográficas de tórax:

1. Mejora de contraste inicial: Se aplica el método de expansión asimétrica del histograma a la imagen original.
2. Localización pulmonar: Se utiliza el ALP para extraer y normalizar la ROI.

Este proceso se ilustra en la Figura 6.

En las siguientes secciones, se presentarán los resultados experimentales que demuestran la eficacia de este método en comparación con las técnicas convencionales de mejora de contraste, utilizando diversas arquitecturas de CNN para la clasificación de imágenes radiográficas de tórax.



Figura 6. Comparación de una imagen radiográfica de tórax en las diferentes etapas del proceso integrado: original, después de aplicar SAHS, y después de obtener la ROI

3. Resultados experimentales

Para evaluar la eficacia de SAHS (Statistical Asymmetrical Histogram Stretching) en comparación con las técnicas convencionales, realizamos una serie de experimentos utilizando diversas arquitecturas de redes neuronales convolucionales (CNN) para la clasificación de imágenes radiográficas de tórax. Los resultados se compararon con el rendimiento de las mismas arquitecturas utilizando HE y CLAHE.

3.1 Configuración Experimental

Se utilizó un conjunto de datos de 2,700 imágenes de radiografías de tórax, con 1,350 imágenes de pacientes saludables y 1,350 de pacientes con neumonía, las cuales fueron usadas para entrenar y probar los modelos de CNN. Estas imágenes se encuentran separadas de origen al momento de la descarga, lo cual implica que ambas clases podrían tener condiciones diferentes inherentes a su fuente original. Por lo anterior resulta obligado un ajuste de contraste para garantizar que las imágenes tanto normales como de neumonía se encuentren en las mismas condiciones de brillo y contraste. Estas imágenes fueron tomadas de la base de datos COVID-19_Radiography_Dataset de Kaggle [21]. Utilizamos seis arquitecturas de CNN diferentes: AlexNet, Compact, Enhanced, ResNet-18, MobileNetV2 y ResNet-50, todas disponibles en la plataforma MVTEC Deep Learning Tool [14]. Cada modelo fue entrenado y evaluado. El conjunto de datos consistió en radiografías de tórax etiquetadas como "normal" o "neumonía". Se utilizó validación cruzada de 5 pliegues para evaluar el rendimiento de los modelos.

3.2 Resultados de Clasificación

La Tabla 2 muestra los resultados de precisión obtenidos para cada arquitectura CNN y método de preprocesamiento:

Tabla 2. Resultados de precisión (tasa de aciertos) de los experimentos.

Modelo CNN	HE	CLAHE	SAHS
AlexNet	89.4%	91.6%	92.8%
Compact	92.1%	91.6%	93.8%
Enhanced	93.1%	93.6%	95.1%
ResNet-18	93.8%	92.1%	96.3%
MobileNetV2	95.6%	96.0%	95.1%
ResNet-50	93.6%	95.3%	95.8%

3.3 Análisis de Resultados

1. Superioridad del método SAHS: Nuestro método SAHS superó a CLAHE en la mayoría de los casos, con mejoras notables en AlexNet, Compact, Enhanced y ResNet-18.
2. Rendimiento por arquitectura:
 - ResNet-18 mostró la mayor mejora con SAHS, alcanzando un 96.3% de precisión.
 - MobileNetV2 y ResNet-50 tuvieron un rendimiento similar con CLAHE y SAHS, con una ligera ventaja para SAHS en ResNet-50.
3. Consistencia: SAHS demostró ser más consistente en la mejora de la precisión a través de diferentes arquitecturas, sugiriendo una mejor adaptabilidad a diversos modelos de CNN.
4. Eficacia en arquitecturas más simples: La mejora fue más pronunciada en arquitecturas más simples como AlexNet y Compact, indicando que SAHS puede ser especialmente beneficioso cuando se utilizan modelos menos complejos.

4. Conclusiones y trabajo futuro

Los resultados demuestran que SAHS (*Statistical Asymmetrical Histogram Stretching*) es efectivo para mejorar la precisión de la clasificación de imágenes radiográficas de tórax en una variedad de arquitecturas CNN. En la mayoría de los casos, supera al método CLAHE convencional. La eficacia de SAHS puede atribuirse a su capacidad para adaptar la mejora de contraste a la naturaleza asimétrica de los histogramas en imágenes radiográficas de tórax, preservando información crítica para el diagnóstico mientras mejora la visibilidad de estructuras relevantes. Es importante notar que mientras SAHS mostró mejoras consistentes, la magnitud de la mejora varió entre las diferentes arquitecturas. Esto sugiere que la elección del método de preprocesamiento debe considerarse en conjunto con la selección de la arquitectura CNN para optimizar el rendimiento general del sistema de clasificación. Las principales contribuciones de este artículo son dos: un método de ajuste de contraste para histogramas asimétricos SAHS como los que presentan las imágenes radiográficas de tórax, y la integración exitosa de SAHS con el Algoritmo Localizador de Pulmones (ALP) para una clasificación más precisa de la neumonía en imágenes radiográficas de tórax. En conclusión, estos resultados respaldan la eficacia del método propuesto SAHS en este artículo como una técnica de preprocesamiento valiosa para mejorar la precisión en la clasificación de imágenes radiográficas de tórax utilizando diversas arquitecturas de CNN. Como trabajo futuro se propone analizar aún más detalladamente la forma del histograma en este tipo de radiografías para desarrollar un método de ajuste de contraste basado completamente en la forma típica de esta clase de histogramas. Así mismo, para realizar dicho ajuste de contraste de toda la imagen podrían tomarse como referencia ciertas zonas o subregiones de brillo estable tales como la columna vertebral.

Referencias

- [1] Zhang, R., Tie, X., Qi, Z., Bevins, N., Zhang, C., Griner, D., Song, T., Nadig, J., Schiebler, M., Garrett, J., Li, K., Reeder, S., & Chen, G. (2020). Diagnosis of Coronavirus Disease 2019 Pneumonia by Using Chest Radiography: Value of Artificial Intelligence. *Radiology*, 298, E88 - E97. <https://doi.org/10.1148/radiol.2020202944>.

- [2] Zech, J., Badgeley, M., Liu, M., Costa, A., Titano, J., & Oermann, E. (2018). Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLoS Medicine*, 15. <https://doi.org/10.1371/journal.pmed.1002683>.
- [3] Ferreira, J., Cárdenas, D., Moreno, R., Rebelo, M., Krieger, J., & Gutierrez, M. (2020). Multi-View Ensemble Convolutional Neural Network to Improve Classification of Pneumonia in Low Contrast Chest X-Ray Images. 2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC), 1238-1241. <https://doi.org/10.1109/EMBC44109.2020.9176517>.
- [4] Cleverley, J., Piper, J., & Jones, M. M. (2020). The role of chest radiography in confirming covid-19 pneumonia. *BMJ*, m2426. doi:10.1136/bmj.m2426
- [5] Adam, M.Y., Saeed, M.M., & Ahmed, A.S. (2015). T Medical Image Enhancement Application Using Histogram Equalization in Computational Libraries.
- [6] da Silva, E. A. B., & Mendonça, G. V. (2005). Digital image processing. In W.-K. Chen (Ed.), *The Electrical Engineering Handbook* (pp. 891-910). Academic Press. <https://doi.org/10.1016/B978-012170960-0/50064-5>
- [7] S. Patel, K. P. Bharath, S. Balaji, and R. K. Muthu, "Comparative Study on Histogram Equalization Techniques for Medical Image Enhancement," in *Proc. Int. Conf. Computational Intelligence and Data Science (ICCIDS 2019)*, 2019.
- [8] Salem, N., Malik, H., & Shams, A. (2019). Medical image enhancement based on histogram algorithms. *Procedia Computer Science*, 163, 300-311. <https://doi.org/10.1016/j.procs.2019.12.112>
- [9] Rehm, K., & Dallas, W. (1989). Artifact Suppression in Digital Chest Radiographs Enhanced with Adaptive Histogram Equalization., 1092. <https://doi.org/10.1117/12.953270>.
- [10] Shendge, R., & Shengde, T. (2022). Image Pre-processing techniques comparison: COVID-19 detection through Chest X-Rays via Deep Learning. *International Journal of Scientific Research in Science, Engineering and Technology*. <https://doi.org/10.32628/ijrest229212>.
- [11] Nacereddine, N., & Ziou, D. (2015). Asymmetric Generalized Gaussian Mixtures for Radiographic Image Segmentation., 521-532. https://doi.org/10.1007/978-3-319-26227-7_49.
- [12] Kao, E., Kuo, Y., Hsu, J., Chou, M., & Liu, G. (2011). Zone-based analysis for automated detection of abnormalities in chest radiographs. *Medical physics*, 38 7, 4241-50. <https://doi.org/10.1118/1.3595110>.
- [13] Arzhaeva, Y., Prokop, M., Tax, D., Jong, P., Schaefer-Prokop, C., & Ginneken, B. (2007). Computer-aided detection of interstitial abnormalities in chest radiographs using a reference standard based on computed tomography. *Medical physics*, 34 12, 4798-809.

- [14] Plataforma plataforma MVTEC Deep Learning Tool. Consultado en:
<https://www.mvtec.com/downloads/deep-learning-tool>
- [15] Koundur, N. C., Anil, B., Dhanulavagai, P. M., Ganiger, R., & Ramadoss, B. (2023). Pneumonia detection in chest X-rays using transfer learning and TPUs. *Engineering, Technology and Applied Science Research*, 13, 11878–11883.
- [16] Kavitha, M., Srinivasan, R., Triveni, R., & Chowdary, C. P. (2023). Pneumonia detection using deep learning techniques. En 2023 IEEE International Conference on Research Methodologies in Knowledge Management, Artificial Intelligence and Telecommunication Engineering (RM-MATE 2023).
- [17] Ramli, A. A. B., Zulkifli, Z., Ahmad, S., & Ghazali, N. (2023). Automatic pneumonia detection through chest X-ray image-based. En 2023 4th International Conference on Artificial Intelligence and Data Sciences: Discovering Technological Advancement in Artificial Intelligence and Data Science (AiDAS 2023) (pp. 355–360).
- [18] Kanjanasurat, I., Tehongspakui, K., Puriyaohong, B., & Lasakul, A. (2023). CNN–RNN network integration for the diagnosis of COVID-19 using chest X-ray and CT images. *Sensors*, 23.
- [19] S. E. Ayala-Raggi, A. E. Picazo-Castillo, A. Barreto-Flores, and J. F. Portillo-Robledo, "Synergizing Chest X-ray Image Normalization and Discriminative Feature Selection for Efficient and Automatic COVID-19 Recognition," in *Pattern Recognition*, Cham: Springer Nature Switzerland, 2023, pp. 216-229.
- [20] A. E. Picazo-Castillo et al., "Estudio Comparativo entre la Normalización y la Segmentación Semántica de la Región Pulmonar en Imágenes Radiográficas de Tórax para el Reconocimiento Automático de COVID-19," *Abstraction and Application*, vol. 43, pp. 1-11, 2023.0
- [21] COVID-19 Radiography Database. Consultado en:
<https://www.kaggle.com/datasets/tawsifurrahman/covid19-radiography-database>