



Normalización y alineación automática de la forma de la región pulmonar integrada con selección de características discriminantes para detección de neumonía y COVID-19

R. A. Cruz Ovando*, S. E. Ayala Raggi, A. Barreto Flores

^a Facultad de Ciencias de la Electrónica, BUAP, Av. San Claudio y 18 Sur, San Manuel, CP 72570, Puebla, Pue., México;



El análisis automatizado de radiografías de tórax se ha convertido en una herramienta esencial para mejorar la precisión diagnóstica en enfermedades respiratorias como neumonía y COVID-19. Estas imágenes son ampliamente utilizadas por su bajo costo y disponibilidad, sin embargo, su interpretación manual resulta subjetiva y propensa a errores. El presente trabajo propone un sistema basado en aprendizaje profundo para la detección automática de puntos anatómicos de referencia (landmarks) en radiografías de tórax, los cuales permiten normalizar y alinear la forma de la región pulmonar. Esta normalización facilita la posterior detección de patologías mediante la selección de características discriminantes, mejorando la eficiencia y objetividad del diagnóstico médico asistido por computadora.

INTRODUCCIÓN.

El diagnóstico por imágenes médicas enfrenta el reto de combinar precisión, rapidez y objetividad en la interpretación radiológica. En particular, las radiografías de tórax son una herramienta esencial para detectar patologías pulmonares como neumonía y COVID-19, pero su análisis manual es subjetivo y susceptible a errores humanos.

Para superar esta limitación, los sistemas de diagnóstico asistido por computadora (CADx) utilizan modelos de aprendizaje profundo capaces de detectar landmarks anatómicos y normalizar la geometría torácica. Sin embargo, la detección precisa de coordenadas anatómicas requiere optimizar simultáneamente exactitud numérica y consistencia anatómica, algo que las funciones de pérdida tradicionales no logran por sí solas. Este trabajo presenta el desarrollo de una Función de Pérdida Combinada que integra conocimiento anatómico y criterios geométricos dentro del proceso de entrenamiento de una red neuronal convolucional (ResNet-18). La propuesta mejora la localización automática de landmarks en radiografías de tórax, permitiendo una alineación y normalización más coherente de la región pulmonar para su posterior clasificación en casos de COVID-19 y neumonía.

TEORÍA

La detección automática de landmarks anatómicos en radiografías de tórax constituye una tarea esencial para la normalización geométrica y el análisis estructural del sistema respiratorio. Estos landmarks son puntos anatómicos de referencia —como los ápices pulmonares, los ángulos costofrénicos o los bordes cardíacos— cuya correcta localización permite alinear imágenes, calcular proporciones y comparar morfologías entre diferentes individuos o estados patológicos. Sin embargo, la identificación automática de dichos puntos presenta un reto técnico y conceptual: los métodos clásicos basados en plantillas o transformadas de Hough son sensibles a variaciones de iluminación, ruido o presencia de opacidades pulmonares. Por ello, se ha recurrido a técnicas de aprendizaje profundo, particularmente a las redes neuronales convolucionales (CNN), que aprenden representaciones jerárquicas de las imágenes sin depender de descriptores manuales.

Modelo convolucional y regresión de coordenadas

El modelo propuesto se fundamenta en una arquitectura ResNet-18, seleccionada por su capacidad para capturar patrones visuales complejos con bajo costo computacional. Esta red utiliza bloques residuales que permiten mantener la información de niveles anteriores y evitar el problema del desvanecimiento del gradiente, logrando un aprendizaje más estable incluso en redes profundas.

La red se entrena bajo un esquema de aprendizaje supervisado para predecir coordenadas continuas (x,y)(x,y) asociadas a cada landmark anatómico. Formalmente, el problema se plantea como una regresión multisalida, donde para cada imagen I , la red estima un vector

$$\hat{Y} = [x_1, y_1, x_2, y_2, \dots, x_n, y_n]$$

que se compara con las coordenadas reales Y mediante una función de pérdida diseñada para minimizar el error de predicción. No obstante, las pérdidas convencionales, como el Error Cuadrático Medio (MSE) o la L1 Loss, no consideran las relaciones espaciales entre landmarks, ni las restricciones anatómicas del cuerpo humano. Esto puede llevar a predicciones numéricamente correctas, pero geométricamente incoherentes (por ejemplo, un pulmón desalineado o un corazón desplazado).

Función de Pérdida Combinada con restricciones geométricas

Para resolver esta limitación, se desarrolló una Función de Pérdida Combinada (L_{total}) que incorpora tres términos complementarios: Wing Loss (L_{Wing}), Symmetry Loss (L_{sym}) y Distance Preservation Loss (L_{dist}).

La formulación general es:

$$L_{total} = \lambda_1 L_{Wing} + \lambda_2 L_{sym} + \lambda_3 L_{dist}$$

donde los parámetros $\lambda_1, \lambda_2, \lambda_3$ son coeficientes de ponderación que controlan la contribución de cada componente al aprendizaje total.

Wing Loss (L_{Wing})

Esta pérdida fue diseñada específicamente para tareas de regresión de coordenadas, especialmente en reconocimiento facial o anatómico. A diferencia de las pérdidas cuadráticas tradicionales, Wing Loss amplifica los gradientes cuando el error es pequeño, permitiendo ajustes más finos cerca de la posición real del landmark.

Su comportamiento combina la estabilidad del error absoluto con la sensibilidad logarítmica en regiones próximas al objetivo, promoviendo una convergencia más precisa y evitando saturaciones de gradiente.

Conclusiones: La implementación de una Función de Pérdida Combinada constituye el eje metodológico de este trabajo, al integrar conocimiento médico explícito dentro del proceso de aprendizaje automático. A diferencia de las pérdidas puramente estadísticas, la propuesta guía al modelo no solo a minimizar errores numéricos, sino a preservar la anatomía y mantener la coherencia espacial del tórax. La suma ponderada: $L_{total} = \lambda_1 L_{Wing} + \lambda_2 L_{sym} + \lambda_3 L_{dist}$ representa un enfoque híbrido que combina precisión matemática, equilibrio anatómico y estabilidad geométrica. Esta formulación mejora la localización de landmarks, reduce asimetrías y optimiza la alineación de la región pulmonar, generando radiografías normalizadas idóneas para análisis posteriores como segmentación, detección de patologías o seguimiento clínico longitudinal. Los resultados confirman que incorporar conocimiento anatómico en el diseño de funciones de pérdida es una estrategia efectiva y generalizable a múltiples aplicaciones médicas. Este principio abre la puerta a sistemas de inteligencia artificial más confiables, explicables y útiles para el personal de salud en el diagnóstico de enfermedades respiratorias.

Matemáticamente, se define como:

$$L_{Wing}(e) = \begin{cases} w \ln \left(1 + \frac{|e|}{\epsilon} \right), & \text{si } |e| < w \\ |e| - C, & \text{en otro caso} \end{cases}$$

donde e es el error de predicción, w el rango lineal y ϵ un parámetro de suavizado.

Este componente garantiza que el modelo aprenda ubicaciones anatómicas precisas, esenciales para el alineamiento pulmonar.

♦ Symmetry Loss (L_{sym}) El tórax humano presenta una simetría bilateral aproximada, lo que permite modelar las relaciones entre landmarks pares (por ejemplo, ápice pulmonar izquierdo y derecho, base pulmonar izquierda y derecha). La Symmetry Loss penaliza las diferencias en posición y distancia entre puntos simétricos respecto al eje medio del cuerpo, preservando la geometría torácica incluso en casos donde las intensidades radiográficas difieren entre lados. Esta pérdida se define como:

$$L_{sym} = \frac{1}{N} \sum_{i=1}^N \| (x_i - x'_i) - d_{ref} \|$$

donde (x_i, x'_i) son las coordenadas de los landmarks simétricos y d_{ref} representa la distancia esperada promedio entre ellos en un tórax anatómicamente correcto. El resultado es un modelo que aprende no solo la posición de cada punto, sino también su relación con la estructura global, evitando deformaciones y asimetrías implausibles.

♦ Distance Preservation Loss (L_{dist}). Finalmente, la Distance Preservation Loss introduce una restricción que asegura que las distancias relativas entre landmarks se mantengan coherentes con la anatomía torácica. Por ejemplo, la distancia entre el ápice pulmonar y el diafragma debe conservar proporciones similares entre distintos pacientes, incluso si varía la escala de la imagen. Se calcula como:

$$L_{dist} = \frac{1}{M} \sum_{(i,j) \in P} \| \hat{p}_i - \hat{p}_j \| - \| p_i - p_j \|$$

donde P es el conjunto de pares anatómicos relevantes, p^i y p_i son las coordenadas predichas y reales respectivamente. Este término refuerza la coherencia geométrica global, impidiendo que la red ubique landmarks en posiciones numéricamente correctas pero desproporcionadas entre sí.

RESULTADOS EXPERIMENTALES

El modelo se entrenó sobre un conjunto de 956 radiografías de tórax, que incluyen pacientes sanos, casos de neumonía viral y COVID-19. Se aplicaron transformaciones de preprocesamiento (normalización, aumentación y escalado) y se evaluó el desempeño bajo distintos valores de los coeficientes λ para analizar la influencia de cada componente de pérdida. Los resultados experimentales muestran que la Función de Pérdida Combinada supera de forma significativa a las funciones tradicionales basadas únicamente en error cuadrático medio (MSE).

- Con $\lambda_1 = 1.0$, $\lambda_2 = 0.3$, $\lambda_3 = 0.2$, se obtuvo un Error Radial Medio (MRE) de 7.9 píxeles, dentro del rango de excelencia clínica.
- La incorporación de L_{sym} mejoró la simetría bilateral en un 11 %, y L_{dist} redujo la distorsión geométrica promedio en un 9 %.
- Visualmente, las predicciones del modelo presentan landmarks alineados de manera coherente incluso en imágenes con opacidades o deformaciones provocadas por infección pulmonar.

Las comparaciones entre fases de entrenamiento evidencian que la pérdida geométrica progresiva permite un aprendizaje más estable, con menor sobreajuste y mayor interpretabilidad anatómica. Además, la inferencia se realiza en menos de 1 segundo por imagen, demostrando la viabilidad computacional del sistema en entornos clínicos.





Fig. 5. Visualización de landmarks con restricciones superpuestas en una imagen real.





Fig. 4. Visualización de landmarks con restricciones superpuestas