

Metodología Completa: Preprocesamiento + Eigenfaces + Fisher + KNN

Este documento contiene la metodología completa incluyendo la etapa de preprocesamiento (predicción + warping) que es crucial para entender el proyecto.

ETAPA 0: PREPROCESAMIENTO (PREDICCIÓN + WARPING)

Ejemplos de Imágenes del Dataset

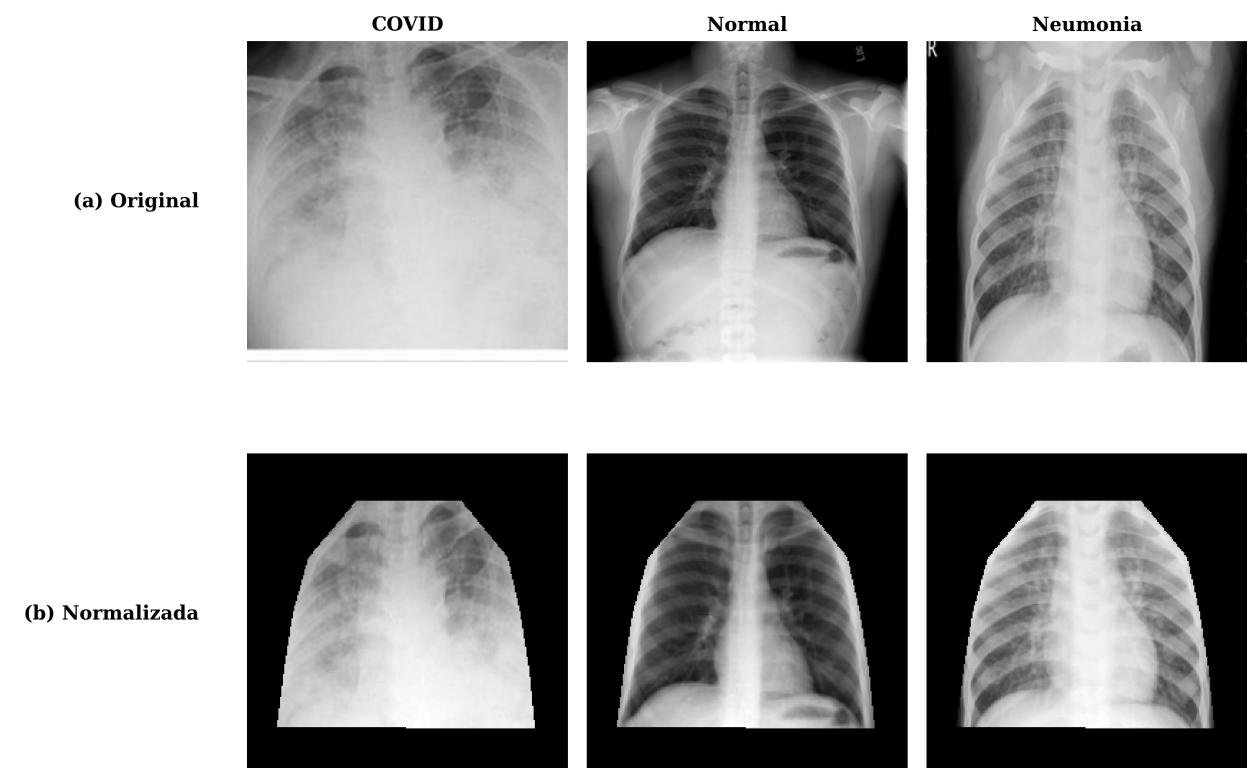


Figura 1: Ejemplos del dataset mostrando imágenes originales (arriba) y warped (abajo).

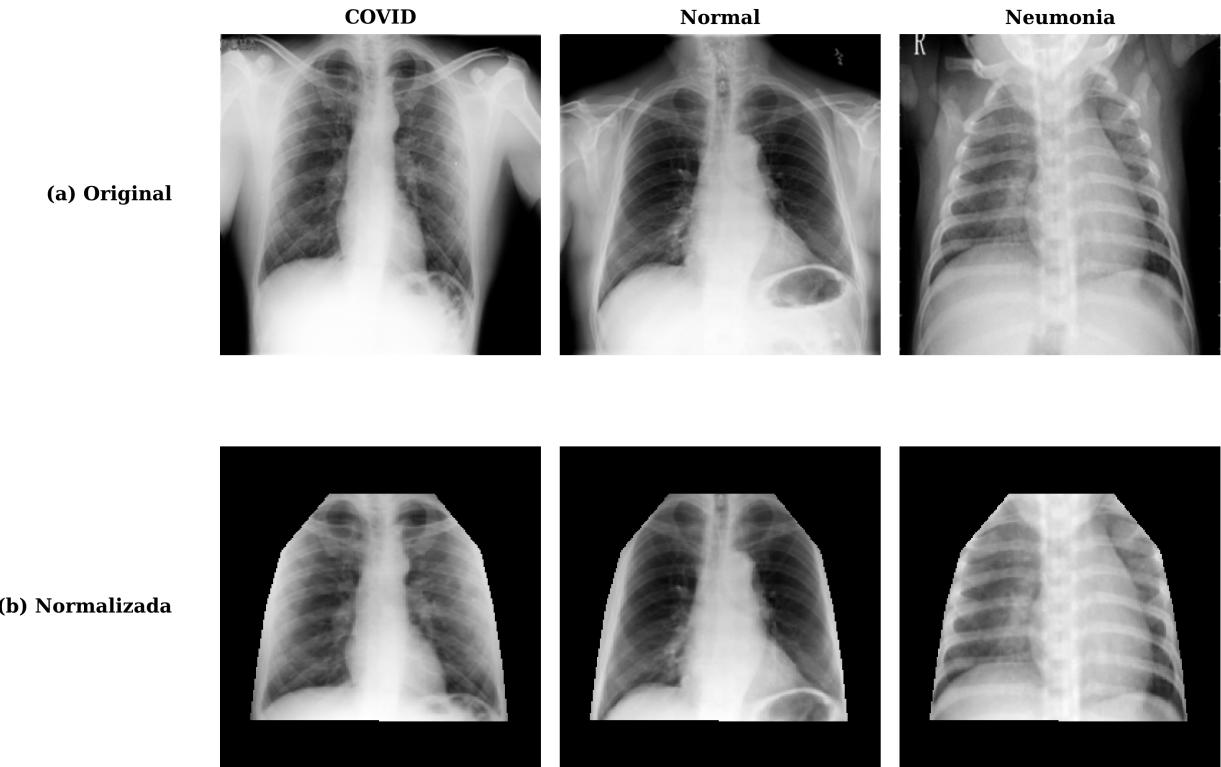


Figura 2: Más ejemplos del dataset mostrando la transformación warping.

Paso 1. Predicción de Landmarks

Objetivo: localizar 15 landmarks por radiografía para el warping.

Qué se hace:

- Se normaliza la imagen (CLAHE + resize 224x224).
- El modelo predice 15 puntos (30 coords) en [0,1].

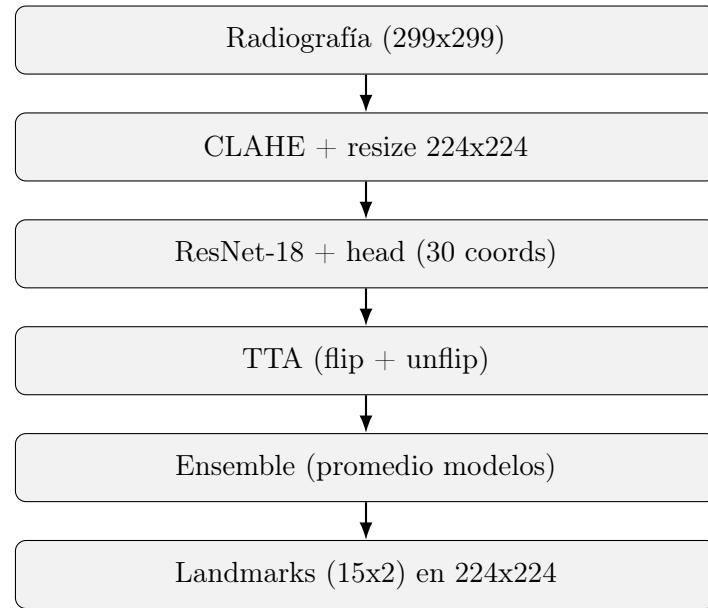
Datos y configuración:

- 957 radiografías con 15 landmarks (dividido en 75 % train/15 % val/10 % test).
- ResNet-18 preentrenada + cabeza de regresión.
- Loss: Wing Loss en coordenadas normalizadas.
- Salida usada para warping: landmarks en 224x224.

Métrica clave (224x224)

Configuración	Error medio	Mediana	Std
Ensemble (4) + TTA (Test-Time Augmentation)	3.71 px	3.17 px	2.42 px

Diagrama de bloques



Evidencia visual

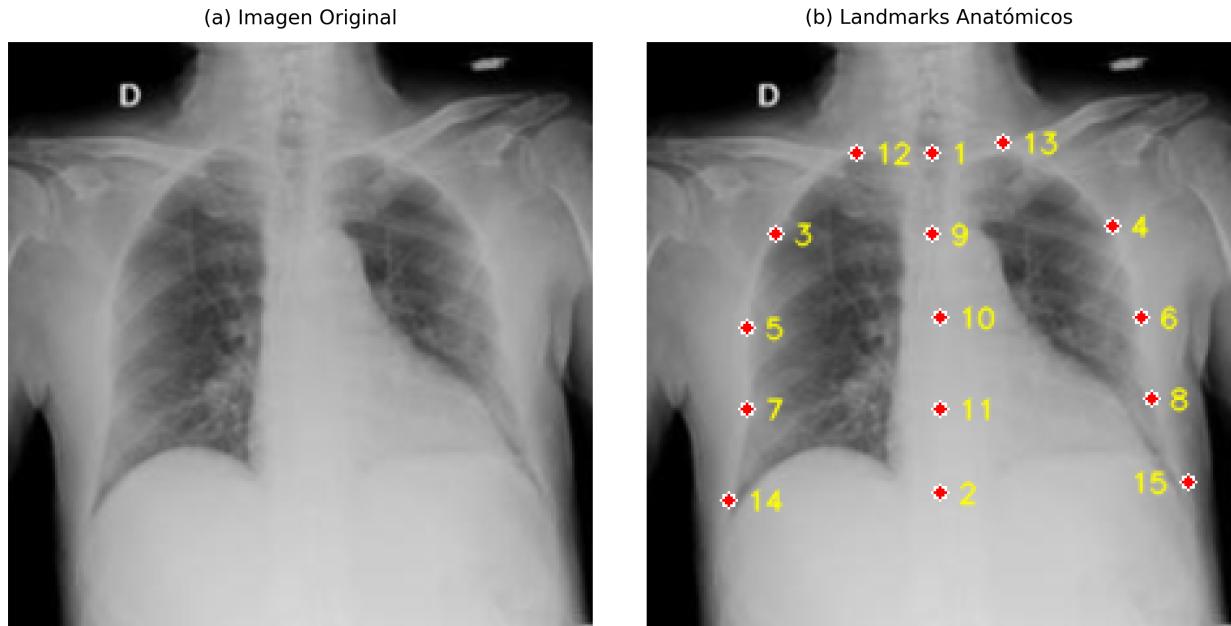


Figura 3: Ejemplo de landmarks predichos sobre una radiografía real.

**Ejemplos de Predicciones por Categoría
(Ensemble 4 Modelos + TTA)**

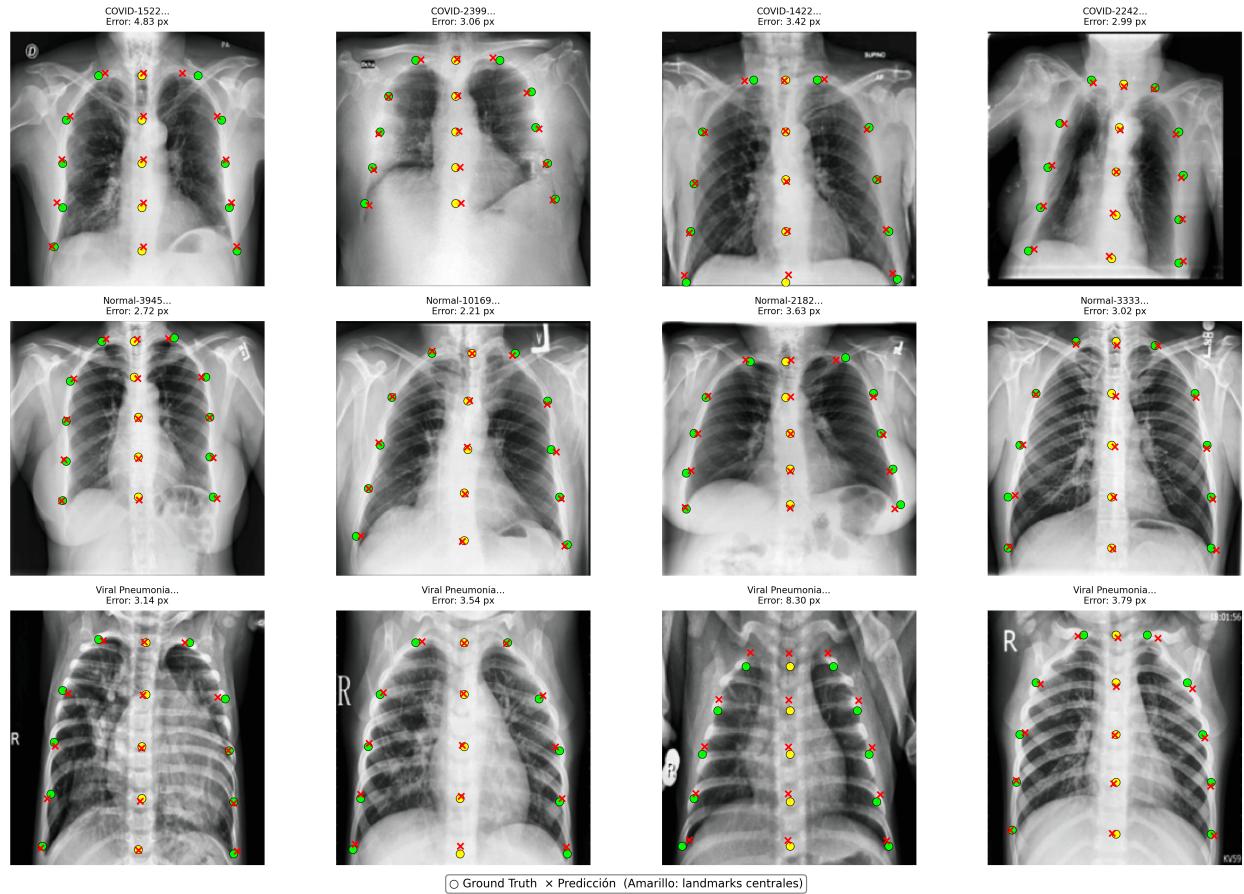


Figura 4: Comparación GT vs predicción (muestra de test).

Paso 2. Forma Canónica (GPA)

Objetivo: construir una forma de referencia única para alinear todas las radiografías.

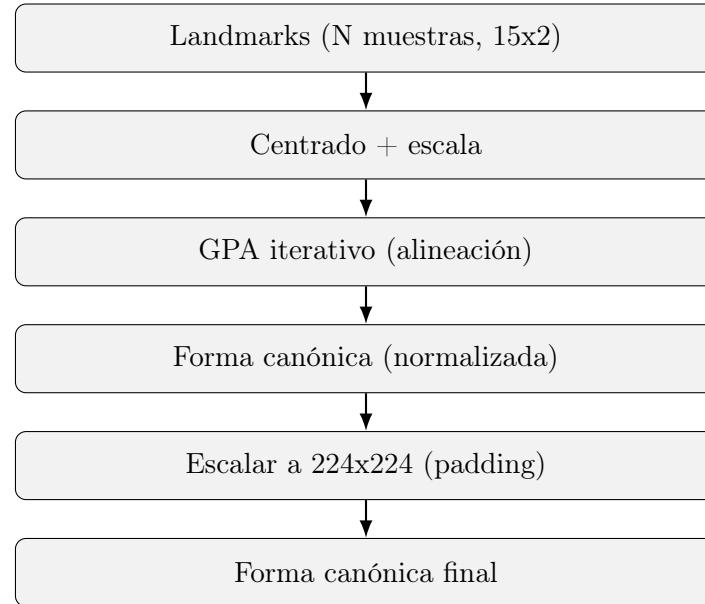
Qué se hace:

- Se usan todas las formas (957 radiografías, 15 landmarks) del dataset.
- GPA (General Procrustes Analysis) elimina traslación, escala y rotación para alinear las formas.
- Se calcula la forma canónica y se escala a 224x224.

Resultado esperado:

- Forma canónica en 224x224 con 15 landmarks.

Diagrama de bloques



Evidencia visual

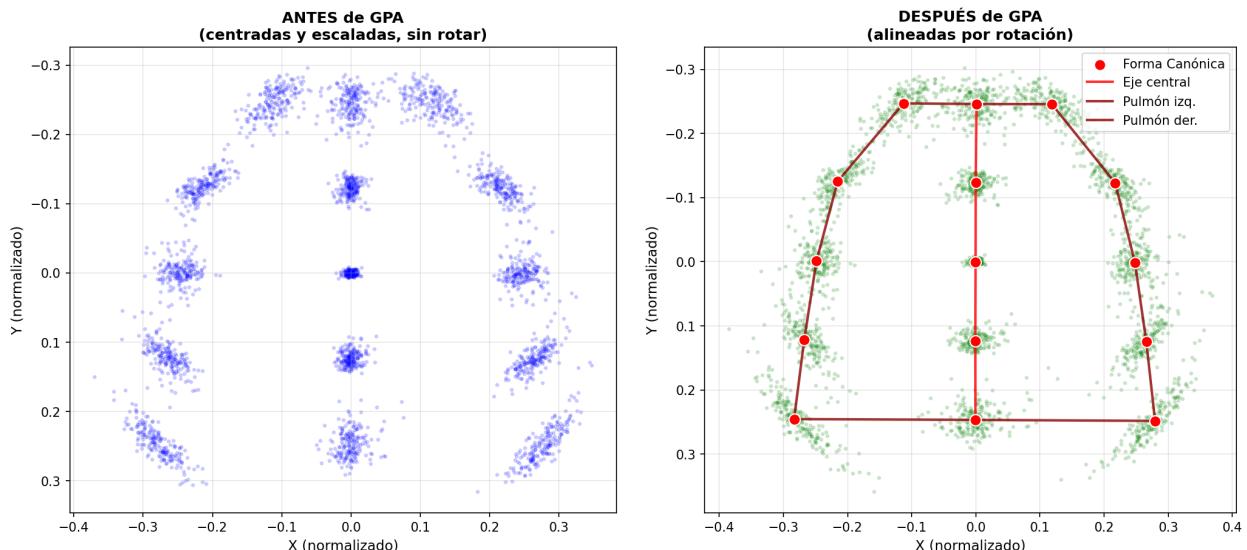


Figura 5: Comparación antes/después; tras centrar y escalar, el cambio principal es la orientación.

Paso 3. Warping Geométrico (Delaunay + Piecewise Affine)

Objetivo: alinear cada radiografía a la forma canónica para normalizar la pose.

Qué se hace:

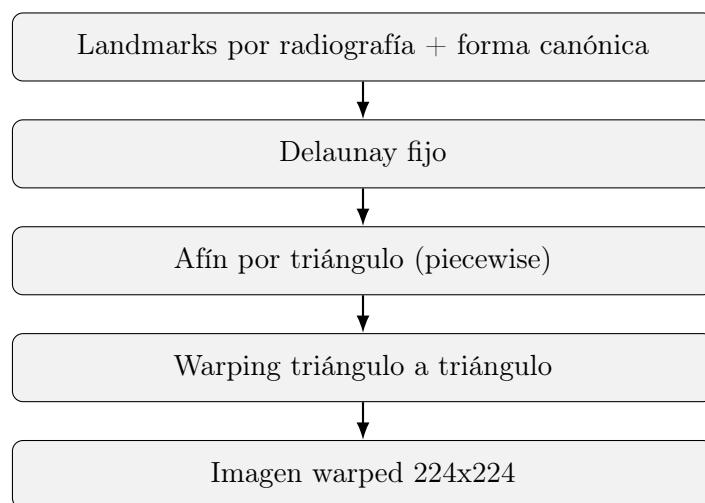
- Se toman los landmarks predichos (Paso 1) y la forma canónica (Paso 2).

- Se usa la triangulación de Delaunay calculada sobre la forma canónica.
- Se aplica una transformación afín por triángulo y se reconstruye la imagen warpeada (224x224).

Resultado esperado:

- Imágenes warped.

Diagrama de bloques



Evidencia visual

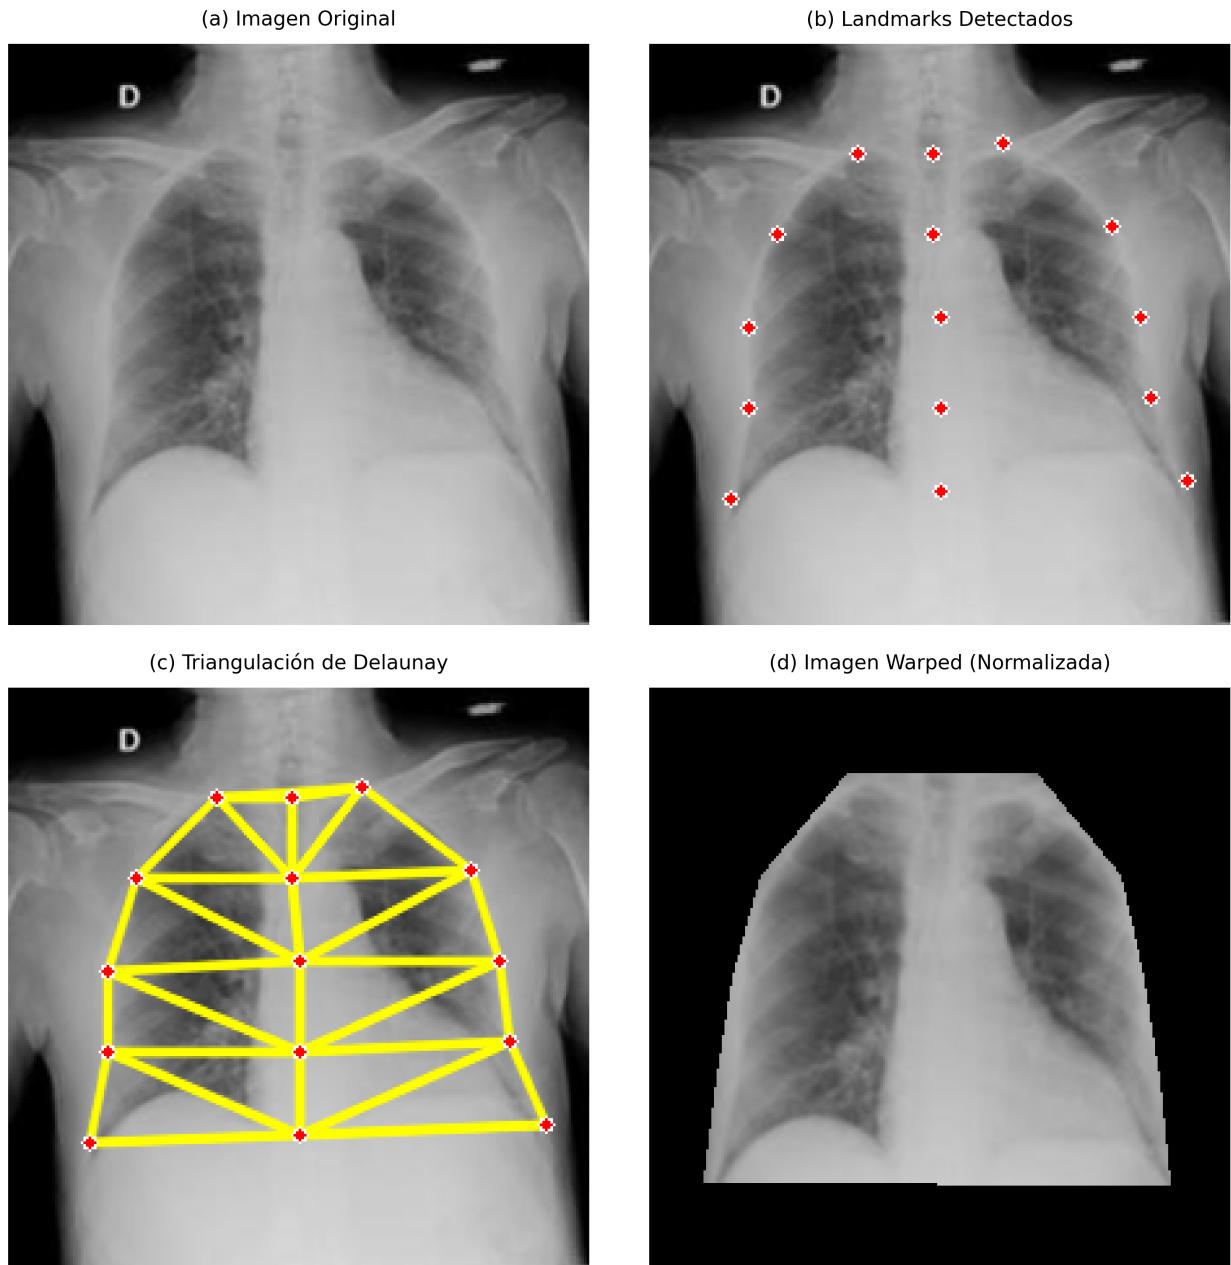


Figura 6: Proceso completo desde la radiografía original hasta la imagen warpeada.

Paso 4. PCA / Eigenfaces (Reducción de Dimensionalidad)

Objetivo: compactar cada radiografía en un conjunto pequeño de componentes principales.

Qué se hace:

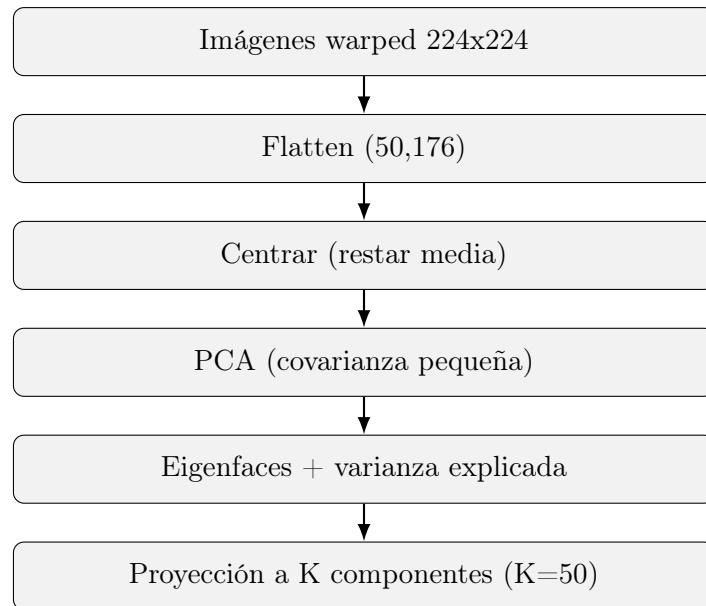
- Se vectorizan las imágenes warped 224x224 (50,176 píxeles).

- Se centra la información y se calcula PCA.
- Se obtienen eigenfaces y varianza explicada.
- Se proyecta a K componentes ($K=50 \approx 95\%$ varianza).

Resultado esperado:

- Representación compacta para cada imagen.
- Eigenfaces que capturan la variabilidad dominante.

Diagrama de bloques



Evidencia visual

Radiografía Promedio (Mean Face)

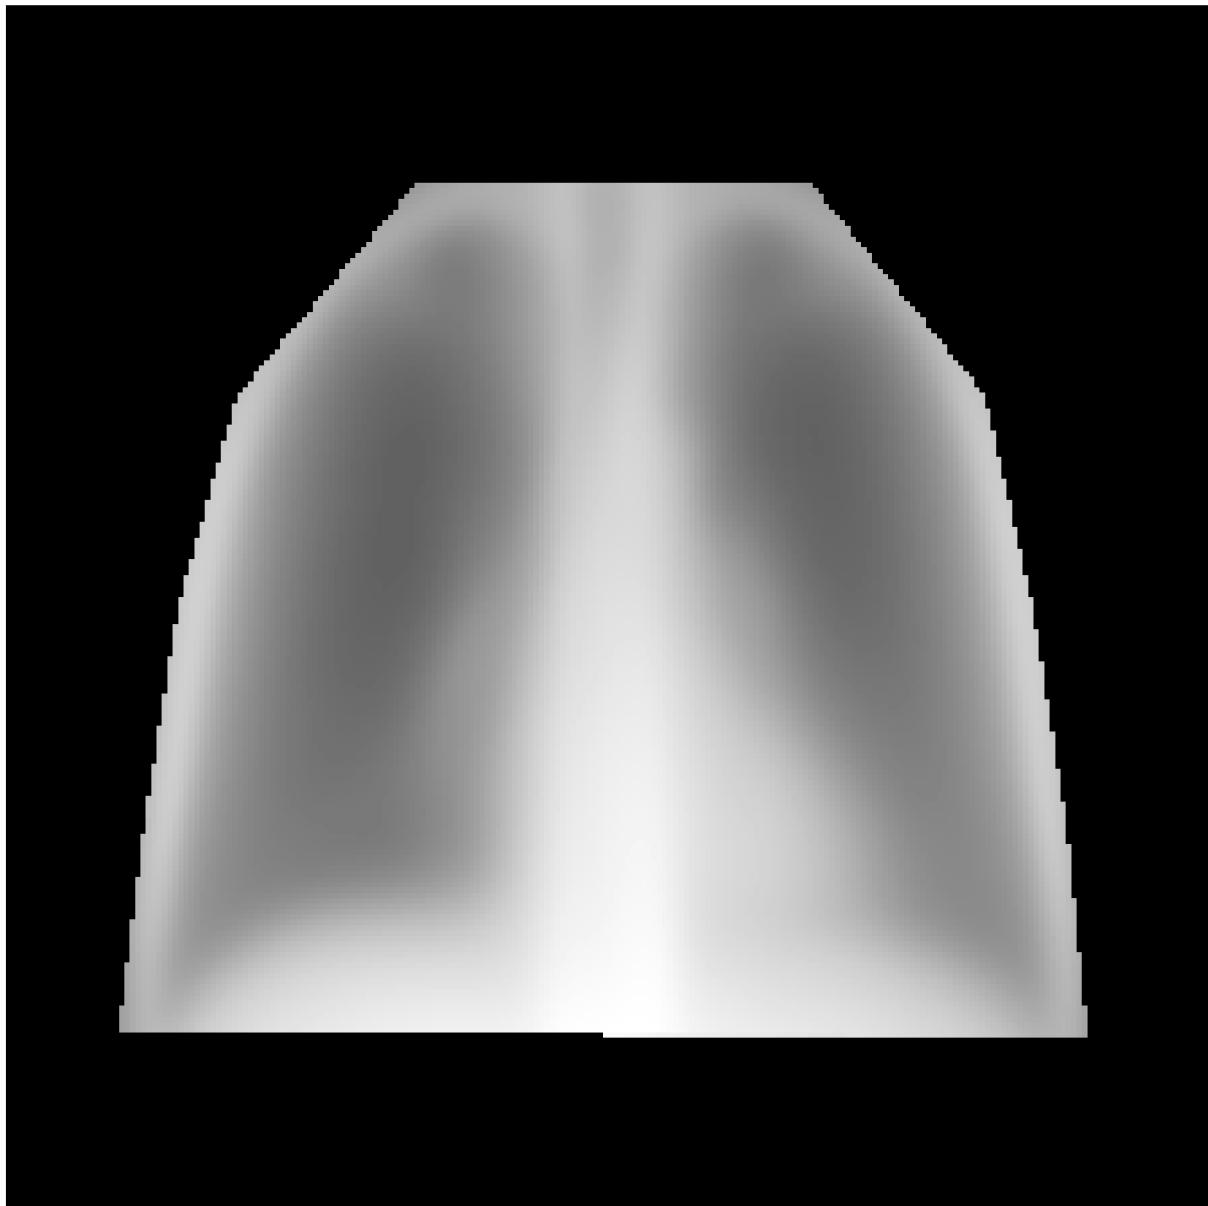


Figura 7: Radiografía promedio (mean face) del dataset warped.

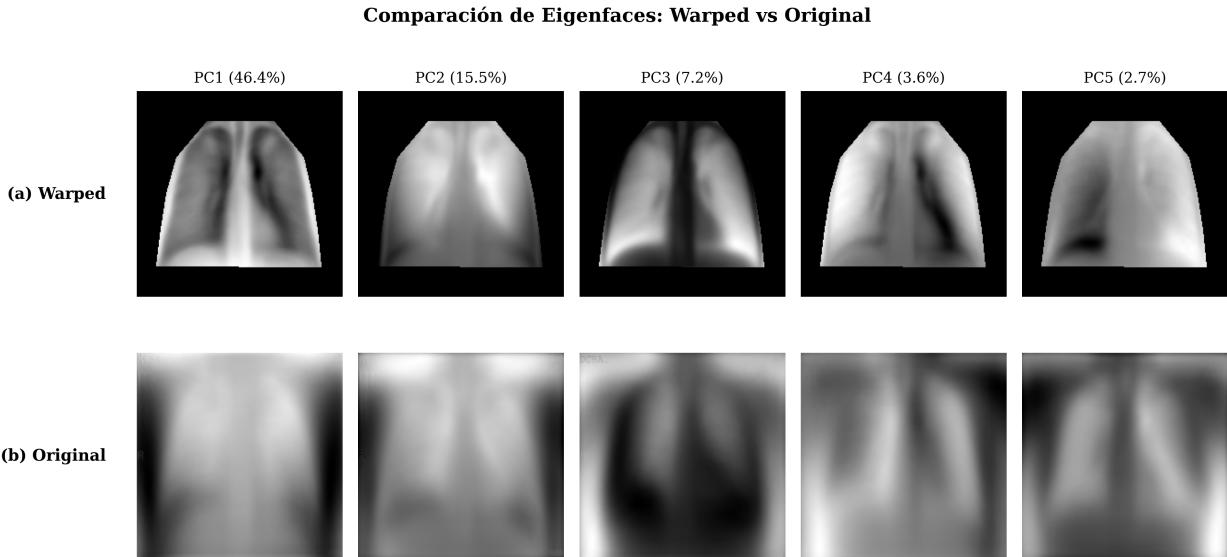


Figura 8: Comparación de eigenfaces entre warped y original.

Paso 5. Estandarización Z-Score (Características PCA)

Objetivo: poner todas las componentes en la misma escala antes de Fisher y KNN.

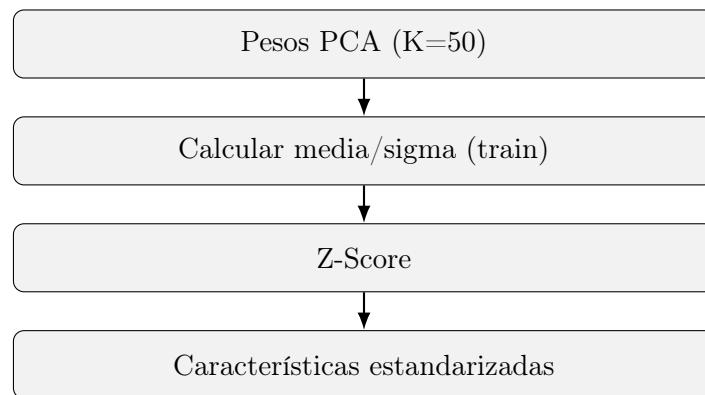
Qué se hace:

- Se calculan media y desviación por componente usando solo datos de entrenamiento.
- Se estandarizan train/val/test con esos mismos parámetros.
- Cada componente queda con media ~ 0 y std ~ 1 .

Resultado esperado:

- Características comparables.

Diagrama de bloques



Evidencia visual

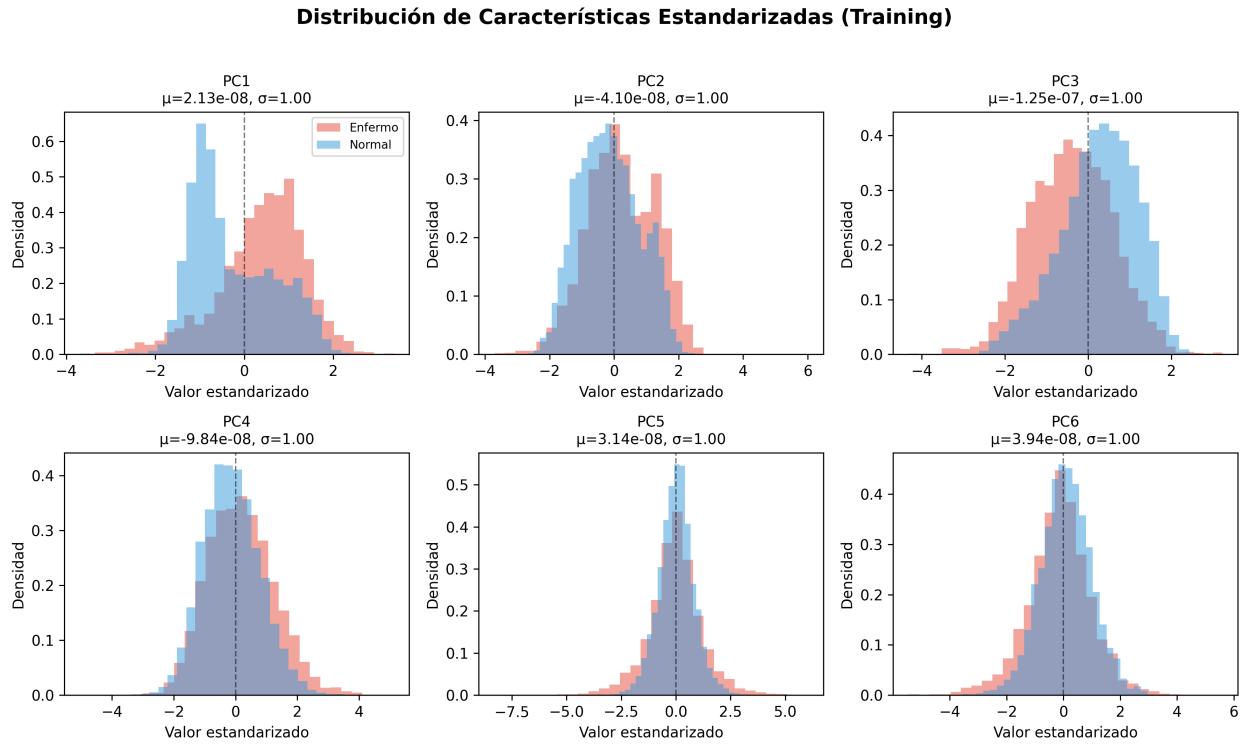


Figura 9: Distribución de las primeras características tras Z-Score (media ~ 0 , std ~ 1).

Paso 6. Criterio de Fisher (Selección Discriminativa)

Objetivo: medir qué componentes PCA separan mejor las clases.

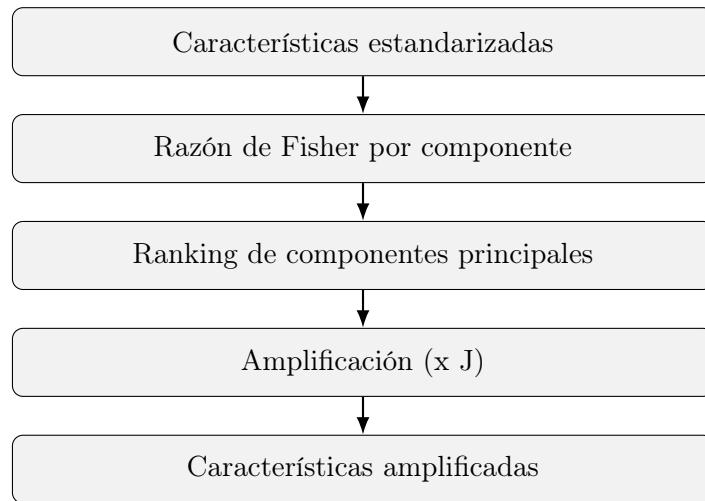
Qué se hace:

- Se calcula la razón de Fisher por componente usando solo entrenamiento.
- Se ordenan las componentes por poder discriminativo.
- Se amplifican las características multiplicando por la razón de Fisher.

Resultado esperado:

- Características amplificadas para clasificación.

Diagrama de bloques



Evidencia visual

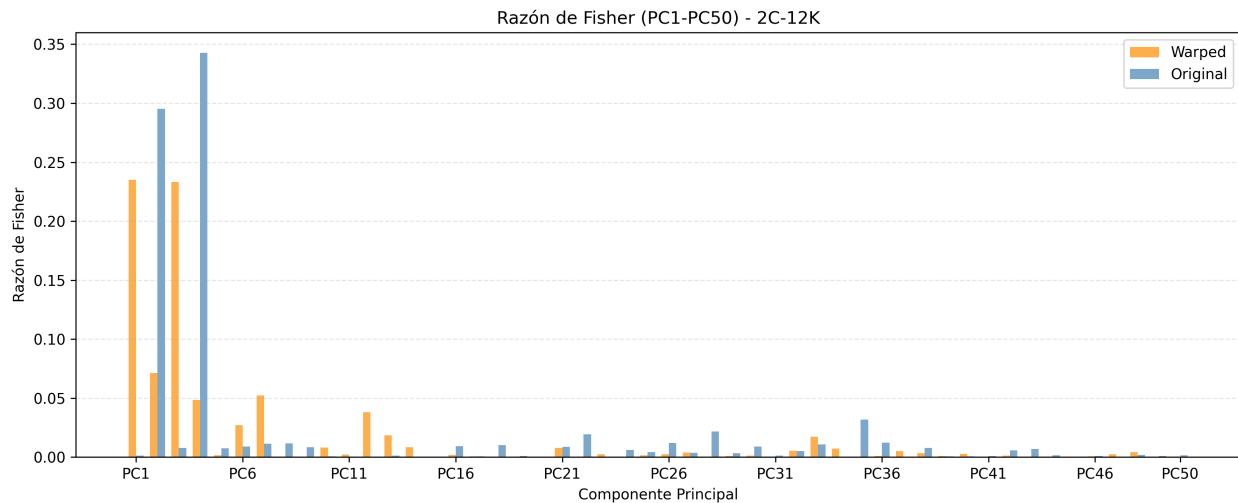


Figura 10: Razón de Fisher por componente (Warped vs Original, 2C-12K).

Paso 7. Clasificación KNN

Objetivo: clasificar las radiografías usando las características amplificadas por Fisher.

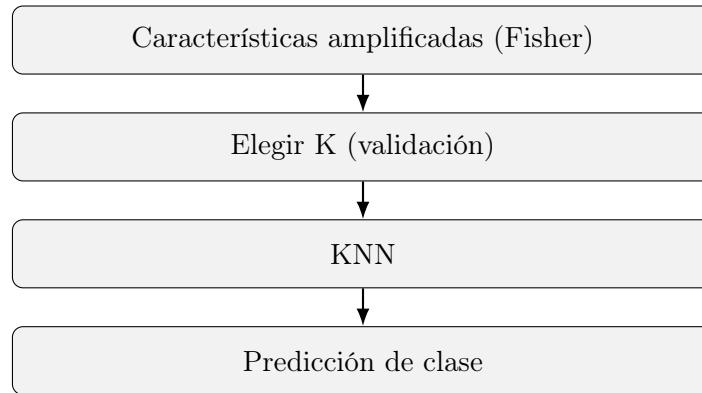
Qué se hace:

- Se usan las características amplificadas (Paso 6).
- Se selecciona K óptimo con validación.
- Se evalúa en test con accuracy y métricas por clase.

Resultado esperado:

- Desempeño final.

Diagrama de bloques



Evidencia visual

Matrices de confusión (2C-12K y 3C-6K)

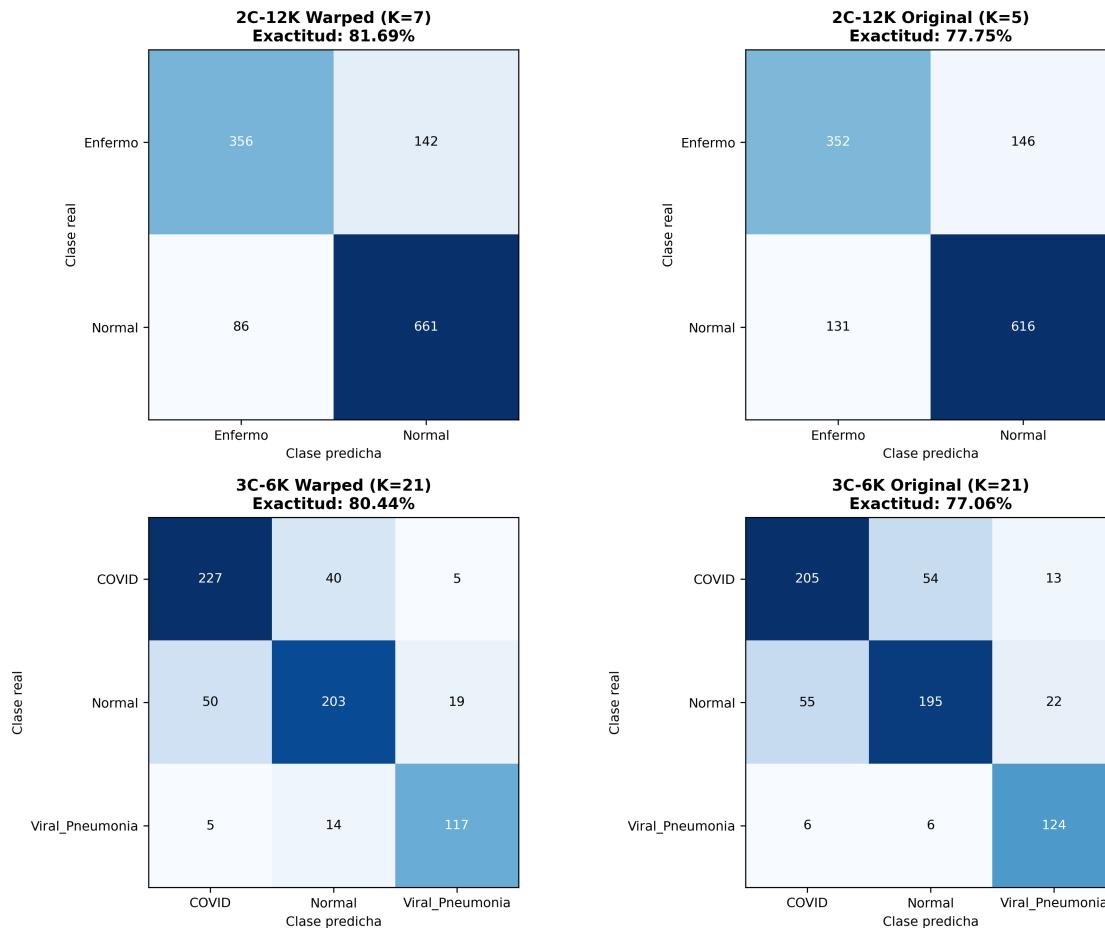


Figura 11: Matrices de confusión para 2C-12K y 3C-6K (Warped vs Original).